

---

# Нейронные сети для обнаружения аномалий в многомерных временных рядах

---

A Preprint

Дмитрий Сергеевич Прокудин  
Факультет ВМК  
МГУ имени М.В.Ломоносова  
Москва, Россия  
TheLoyalist@yandex.ru

Мой научник  
Факультет ВМК  
МГУ имени М.В.Ломоносова  
Москва, Россия  
почтамоегонаучника@gmail.ru

## Abstract

Задача обнаружения аномалий в многомерных временных рядах является актуальной во многих областях, например, в производстве и технологических процессах, где аномальные значения могут указывать на неисправности в системе. Данные могут быть взаимосвязаны друг с другом и иметь сложную структуру, поэтому нейронные сети хорошо подходят для решения данной задачи.

В данной работе сравниваются модели со сложными архитектурами, предназначенными конкретно для прогнозирования многомерных временных рядов, такие как Autoformer и TimesNet, и модели с более простыми архитектурами, предназначенными для работы с последовательностями в общем, такие как рекуррентные нейронные сети и временные свёрточные нейронные сети. Проводится экспериментальное исследование качества прогноза и обнаружения аномалий данными моделями. Рассматривается два метода обнаружения аномалий: на основе разности предсказанных значений и значений исходного ряда и на основе вероятностного подхода. Эксперименты подтверждают применимость рассмотренных моделей и методов для решения данной задачи и показывают преимущество временных свёрточных сетей над специализированными моделями - при более простой архитектуре точность прогноза оказывается выше.

Keywords Нейронные сети · многомерные временные ряды · обнаружение аномалий

## 1 Введение

Задача обнаружения аномалий во временных рядах нередко возникает при эксплуатации сложных технологических систем Darban et al. [2022], Shalyga et al. [2018]. Их работа описывается множеством величин, изменяющихся во времени. Например, это могут быть показания сенсоров и датчиков или состояния различных устройств во время выполнения процесса Shalyga et al. [2018]. Во время нормальной работы эти значения чаще всего ведут себя регулярным образом с характерными значениями или периодичностью. Аномалией в таких данных является отклонение от типичного поведения. Необходимо уметь выявлять такие участки, так как они могут свидетельствовать о наличии сбоев или неисправностей в системе. Обычно части системы взаимосвязаны, поэтому сбой в одной из них может привести к серии сбоев и в других частях. Более того, даже незначительные отклонения от нормальной работы могут привести к существенным неисправностям через достаточно большой промежуток времени. Такая специфика задачи позволяет использовать нейронные сети для её решения, поскольку они способны обрабатывать большие объёмы данных и определять сложные и долговременные связи между компонентами системы Darban et al. [2022], Shalyga et al. [2018], Kravchik and Shabtai [2019], Nie et al. [2023].

Изучаются модели глубокого обучения для прогнозирования временных рядов и рассматриваются методы обнаружения аномалий на основе их прогноза. В Darban et al. [2022], Wu et al. [2022], Wu et al. [2023], Zeng et al. [2022] для прогнозирования временных рядов применяются специализированные модели со сложной архитектурой, при этом более простые и обобщённые модели либо не рассматриваются, либо не приводится полноценное сравнение с ними. В данной работе специализированные модели Autoformer Wu et al. [2022] и TimesNet Wu et al. [2023], показывающие лучшие результаты для прогнозирования временных рядов Wu et al. [2023] на момент написания данной работы, сравниваются с более простыми и обобщёнными рекуррентными LSTM Staudemeyer and Morris [2019], GRU Dey and Salem [2017] и свёрточными моделями TCN Bai et al. [2018]. Проводится два эксперимента: в первом эксперименте на наборе данных MNIST сравниваются рекуррентные нейронные сети и временные свёрточные сети, и выбирается лучшая архитектура для дальнейшего анализа, во втором эксперименте непосредственно решается задача обнаружения аномалий на примере набора данных SWaT Goh et al. [2016] с применением временных свёрточных сетей TCN Bai et al. [2018], модели Autoformer Wu et al. [2022] и модели TimesNet Wu et al. [2023].

## 2 Постановка задачи

Имеется многомерный временной ряд  $X = \{x_1, x_2, x_3, \dots, x_T\}$ ,  $x_t \in R^k$ ,  $k$  - количество каналов в ряду. Необходимо реализовать алгоритм  $F$ , оценивающий аномальность элемента  $x_t$  исходного ряда:  $F(x_t, X) = y_t$ ,  $y_t \in R^m$ . В общем случае, размерность  $m$  оценки может отличаться от размерности  $k$  ряда, например, при оценке аномальности только подвыборки каналов по значениям всех каналов. В данной работе  $m$  принимается равным  $k$ .

## 3 Базовый эксперимент

Все описанные в данной работе эксперименты проводились с применением языка программирования Python и библиотеки PyTorch.

### 3.1 Набор данных MNIST

В данном эксперименте на наборах данных Sequential MNIST и Permuted MNIST сравнивались рекуррентные сети LSTM и GRU и временная свёрточная сеть TCN. Набор данных Sequential MNIST состоит из изображений рукописных цифр размером  $28 \times 28$  пикселей, преобразованных в векторы длины 784. Набор данных Permuted MNIST представляет собой Sequential MNIST, в котором к каждому вектору применили одну и ту же перестановку. Для каждого набора представлена обучающая (50 тыс. объектов) и тестовая (10 тыс. объектов) выборки. Для сравнения моделей исследовалось качество классификации последовательностей из этих наборов данных. Дополнительно для модели TCN было проверено качество дорисовки бинаризованных цифр: на вход модели подавалась первая половина бинаризованной последовательности, по которой пошагово прогнозировалась вторая. Затем после преобразования полученной последовательности к изображению размером  $28 \times 28$  визуально оценивалось его качество.

#### 3.1.1 Обучение и применение моделей

- LSTM и GRU.

Моделям на вход подавалась вся последовательность из 784 элементов, для классификации использовалось последнее скрытое состояние и один линейный слой. Обе модели содержат 1 рекуррентный слой, а размерность внутреннего состояния равна 128.

- TCN.

Для задачи классификации модели на вход подавалась вся последовательность из 784 элементов, использовался последний элемент выходной последовательности и один линейный слой. Для задачи дорисовки на вход подавались первые 783 элемента последовательности и модель обучалась техникой 'teacher-forcing' предсказывать элементы последовательности с 2-го по 784-й. В обеих задачах модель состоит из 8 TCN блоков, размер внутреннего состояния равен 25, размер ядра свёртки - 7.

Для обучения LSTM и GRU использовался оптимизатор RMSprop с  $\text{learning\_rate} = 1e-3$ , для обучения TCN - Adam с  $\text{learning\_rate} = 2e-3$ . LSTM обучалась 50 эпох, GRU обучалась 20 эпох, TCN обучалась

Набор данных	LSTM ( $\approx 68$ тыс. параметров)	GRU ( $\approx 52$ тыс. параметров)	TCN ( $\approx 66$ тыс. параметров)
Sequential MNIST	97.7	97.2	98.9
Permuted MNIST	87.4	82.9	96.7

Таблица 1: Сравнение качества классификации. Представлены % верных ответов на тестовой выборке, для каждой модели указано количество обучаемых параметров.

10 эпох для задачи классификации и 50 эпох для задачи дорисовки. Размер батча был равен 64 во всех случаях.

### 3.1.2 Исследование результатов

Для измерения качества классификации подсчитывалась доля верных ответов на тестовой выборке. Сравнение моделей представлено в таблице.1.

TCN удалось достичь большей точности на обоих наборах данных при сравнимом количестве параметров. На наборе Permuted MNIST качество LSTM и GRU существенно снизилось в то время, как у TCN оно осталось приблизительно на том же уровне. Это означает, что TCN гораздо лучше справляется с задачей запоминания долговременных зависимостей между элементами (так как соседние пиксели изображения могут оказаться далеко друг от друга в Permuted MNIST).

Результаты дорисовки цифр представлены на рис.1. TCN удалось справиться с данной задачей - видно, что все дорисованные цифры имеют высокий уровень сходства с оригинальным изображением.




Рис. 1: Результат дорисовки бинаризованных цифр. На входных изображениях серым цветом обозначены элементы, которые не поступали на вход модели.

### 3.1.3 Выводы

- Эксперимент показал, что TCN лучше запоминает долговременные зависимости между элементами последовательности и качественнее решает задачу классификации цифр.
- По результатам дорисовки цифр видно, что модель TCN отлично справляется с задачей построения новых элементов последовательности, причём хорошие результаты были достигнуты и для Permuted MNIST, в котором соседние элементы последовательности могут быть никак не связаны друг с другом.

- На основе полученных выводов было решено, что TCN подходит для задачи прогнозирования временных рядов и обнаружения аномалий лучше, чем рекуррентные нейронные сети. По этой причине в следующем эксперименте рекуррентные сети не исследовались.

## 4 Основной эксперимент

### 4.1 Набор данных SWaT

Исследование качества прогноза и обнаружения аномалий для временного ряда проводилось на наборе данных SWaT ?. Данные описывают технический процесс очистки воды (схема процесса представлена на рис.?? в Приложении ??) и содержат 51 признак: 26 вещественнозначных замеров с датчиков (например, давление и уровень воды) и 25 дискретных состояний управляющих устройств (например, 'включён-выключен'). Значения записаны с шагом в 1 секунду. Набор разделён на две выборки: 7 неполных дней 'нормальной' работы без аномалий (около 500 тыс. собранных записей) и 6 дней с аномалиями (около 450 тыс. собранных записей). В качестве аномалий выступают атаки на компоненты системы. Всего представлено 36 аномалий: приводится их точная временная разметка, указаны компоненты, на которые была проведена атака, и описание результата атаки. Атаки на систему приводят к нестандартному поведению значений датчиков и состояний управляющих устройств. При этом атака на одну компоненту может повлечь за собой изменения и в других компонентах, поскольку датчики и устройства системы взаимосвязаны.

Перед проведением эксперимента данные были агрегированы скользящим медианным окном (размером в 3000 с.) и нормализованы, частота дискретизации была понижена в 10 раз - новые значения признаков соответствуют медианным значениям за последние 10 с. (медианные окна не пересекались).

Из обработанных данных без аномалий были убраны первые 10000 замеров, так как в течение первого дня после запуска система стабилизировалась и поведение значений признаков отличалось от стандартного. Оставшиеся данные были разбиты на подвыборки: обучающую (31500 замеров) и тестовую (8000 замеров) из 'нормальных' данных для обучения и оценки прогноза нейронных сетей, а также валидационную и тестовую выборки из данных с аномалиями для подбора порогов для обнаружения аномалий и оценки качества обнаружения.

Для эксперимента были выбраны следующие 4 признака из 51: 'FIT101', 'LIT101', 'AIT501' (вещественнозначные) и 'MV101' (дискретный). Ряд 'AIT501' был дополнительно приведён к стационарному виду вычитанием среднего значения за последние 500 замеров. Для каждого признака была подготовлена своя разметка аномалий: были выбраны атаки либо на сам признак, либо на коррелирующие с ним признаки. Корреляция выбранных признаков со всеми компонентами системы представлена на рис.2.

Пример данных представлен на рис.3.

В данном эксперименте сравнивались и исследовались 3 модели: TCN, Autoformer и TimesNet. Для заданного многомерного временного ряда  $X = \{x_1, x_2, x_3, \dots, x_T\}, x_t \in R^k$  модели обучались по входному сегменту длины  $I$  из элементов  $x_{t_0}, x_{t_0+1}, \dots, x_{t_0+I-1}$  предсказывать значения для моментов времени  $t_1, t_1 + 1, \dots, t_1 + L - 1$ . Рассматривались два метода обнаружения аномалий:

1. На основе разности значений прогноза и исходного временного ряда.

Модели обучались предсказывать значения временного ряда  $y_{t_1}, y_{t_1+1}, \dots, y_{t_1+L-1}$ . Для обнаружения аномалии в момент времени  $t$  проводилась оценка значения разности  $y_t$  и  $x_t$ .

2. На основе вероятностного подхода.

Модели обучались предсказывать параметры нормального распределения значений временного ряда. Для обнаружения аномалии в момент времени  $t$  проводится оценка значения стандартного отклонения.

Пороги для оценки и фиксации аномалии подбирались по валидационной выборке.

Поскольку значения ряда 'MV101' дискретные, то для первого метода всеми моделями прогнозировалась вероятность  $\mathcal{P}(MV101 = 1)$ , по которой затем определялось значение ряда. Для второго метода ряд 'MV101' не рассматривался.

#### 4.1.1 Обучение и применение моделей

Для обучения TCN и TimesNet обучающая выборка была разбита на окна длины 400 с шагом в 1 элемент, для Autoformer - на окна длины 100 с шагом в 1 элемент. Для первого метода обнаружения аномалий модели обучались предсказывать значения элементов ряда, для второго метода - предсказывать параметры нормального распределения элементов ряда.

- TCN.

Модель обучалась техникой 'teacher-forcing' по входной последовательности длины 400 в моменты времени  $t_0, t_0 + 1, \dots, t_0 + 399$  предсказывать последовательность длины 400 из значений для элементов ряда в моменты времени  $t_0 + 1, t_0 + 2, \dots, t_0 + 400$ .

Для построения прогноза тестовая и аномальная выборка были разбиты на окна длины 400 с шагом в 20 элементов. Прогноз строится в авторегрессионном формате по 20 элементов.

- Autoformer.

Модель обучалась по входной последовательности длины 100 в моменты времени  $t_0, t_0 + 1, \dots, t_0 + 99$  предсказывать последовательность длины 10 из значений для элементов ряда в моменты времени  $t_0 + 100, t_0 + 101, \dots, t_0 + 109$ .

Для построения прогноза тестовая и аномальная выборка были разбиты на окна длины 100 с шагом в 20 элементов. Модель получала на вход последовательность из элементов ряда и строила прогноз из 10 элементов, из последовательности убиралась первые 10 элементов, а к концу последовательности добавлялся весь прогноз, затем новая последовательность вновь подавалась на вход модели. Данная процедура повторялась по 2 раза, после этого в качестве входной последовательности выбиралось следующее окно из выборки.

- TimesNet.

Модель обучалась по входной последовательности длины 400 в моменты времени  $t_0, t_0 + 1, \dots, t_0 + 399$  предсказывать последовательность длины 10 из значений для элементов ряда в моменты времени  $t_0 + 400, t_0 + 401, \dots, t_0 + 409$ .

Построение прогноза для TimesNet аналогично построению прогноза для Autoformer, но выборки разбиваются на окна длины 400.

Для обучения использовался оптимизатор Adam с  $\text{learning\_rate} = 1e - 4$ , размер батча равнялся 32 при обучении TimesNet для второго метода и 64 для всех остальных моделей. Для первого метода обнаружений аномалий все модели обучались 10 эпох, для второго метода количество эпох варьируется: TCN и TimesNet - 10, Autoformer - 20. Значения параметров моделей представлены в Приложении ??.

#### 4.1.2 Исследование результатов

Рассмотрим первый метод обнаружения аномалий на основе разности значений и сравним результаты моделей. Прогнозы TCN и Autoformer для тестовой выборки представлены на рис. 4, 5, для аномальной - на рис. 6, 7. Далее в этом разделе будут показаны графики с анализом только одного ряда 'FIT101'. Результаты для модели TimesNet и остальных признаков представлены в Приложении ??.

Все модели научились точно предсказывать ряды 'FIT101' и 'LIT101' с ярко выраженной периодичностью, достаточно хорошо предсказывались и значения дискретного признака 'MV101'. Хуже всего прогнозировался ряд 'AIT501' с наиболее сложной структурой без выраженной периодичности - прогноз TCN и Autoformer получался 'зашумлённым', а TimesNet не удалось обучить правильно прогнозировать этот ряд. Прогноз модели TCN является наиболее точным и близким к исходному ряду.

Для каждого ряда был подсчитан модуль разности  $d$  предсказанных значений  $y$  и исходных значений ряда  $x$ . Для момента времени  $t$ :

$$d_t = |y_t - x_t|$$

Дополнительно значения  $d$  были преобразованы с помощью экспоненциального сглаживания:

$$s_1 = d_1,$$

$$s_t = \alpha d_t + (1 - \alpha)s_{t-1}, t > 1, \alpha = 1 - \exp\left(\frac{\log(0.5)}{100}\right)$$

Значения  $s$  для ряда 'FIT101' представлены на рис.8. 'Пики' значений  $s$  приходятся на аномальные зоны, при этом у модели TCN они более выраженные.

Детекция аномалий на всей аномальной выборке по порогу представлена на рис. 9. Можно заметить, что графики обнаружения аномалий для моделей получились очень похожими - разная точность предсказаний всё равно позволила достаточно точно подобрать порог для обнаружения. Также видно, что все аномальные зоны из разметки менее протяжённые, чем зафиксированные - это связано с тем, что нестандартное поведение значений наблюдается не только во время самой атаки на систему, но и во время стабилизации после неё. Более того, некоторые атаки оказывают влияние на параметры процесса не сразу, а через небольшой промежуток времени, поэтому может наблюдаться задержка в обнаружении. По этой причине стандартные метрики, такие как точность, полнота и F1-мера, не будут в полной мере отражать качество обнаружения аномалий. При оценке качества обнаружения аномалий необходимо учитывать и сам факт обнаружения, поэтому для сравнения моделей были подсчитаны доли обнаруженных аномальных зон и средняя задержка обнаружения. Для определения факта обнаружения от каждой аномальной зоны из разметки и от зафиксированной аномальной зоны был оставлен только первый элемент. Результаты сравнения представлены в таблице.2.

Второй метод обнаружения аномалий на основе вероятностного подхода использовать не удалось: исследования показали, что значения стандартного отклонения при прогнозе аномального ряда существенно не отличаются от значений при прогнозе для данных без аномалий. А анализ среднего значения распределения эквивалентен первому методу. По этой причине дальнейшее исследование вероятностного подхода в данной работе не приводится.

#### 4.1.3 Выводы

- Все рассмотренные в данном эксперименте модели способны точно предсказывать нормальные значения вещественнозначных рядов с выраженной периодичностью. Дискретные ряды также предсказываются достаточно хорошо - модели запоминают периоды, в которых значение остаётся постоянным, но нередко ошибаются в 'переходных' зонах изменения величины с одного значения на другое. Хорошо предсказывать вещественнозначный ряд без ярко выраженной периодичности не получилось, но модели TCN и Autoformer смогли выучить 'типичное' поведение значений этого ряда, что позволило использовать их прогноз для обнаружения аномалий и для такого ряда.
- Модель TCN, являясь наиболее простой из рассматриваемых, смогла показать наилучшую точность прогноза нормальных данных.
- Рассмотренный метод обнаружения аномалий на основе разности значений прогноза и исходного ряда позволил фиксировать аномалии с достаточно высоким качеством. Требуемой точности обнаружения не удалось достичь только для дискретного ряда - выбор порога позволяет фиксировать либо слишком малое число настоящих аномалий, либо слишком большое число ложных аномалий. Метод обнаружения на основе вероятностного подхода не удалось использовать для обнаружения аномалий, не зафиксированных первым методом.
- Несмотря на разную точность прогноза, пороги для обнаружения аномалий могут быть подобраны так, что качество обнаружения у разных моделей будет близким. Также метод на основе разности позволяет подбирать пороги и по нормальным данным, если отсутствует выборка с аномалиями.

## 4.2 Figures

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi. See Figure 10. Here is how you add footnotes. <sup>1</sup> Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

---

<sup>1</sup>Sample of the first footnote.

### 4.3 Tables

See awesome Table 3.

The documentation for `booktabs` (‘Publication quality tables in LaTeX’) is available from:

<https://www.ctan.org/pkg/booktabs>

### 4.4 Lists

- Lorem ipsum dolor sit amet
- consectetur adipiscing elit.
- Aliquam dignissim blandit est, in dictum tortor gravida eget. In ac rutrum magna.

### Список литературы

- Zahra Zamanzadeh Darban, Geoffrey I. Webb, Shirui Pan, Charu C. Aggarwal, and Mahsa Salehi. Deep learning for time series anomaly detection: A survey, 2022.
- Dmitry Shalyga, Pavel Filonov, and Andrey Lavrentyev. Anomaly detection for water treatment system based on neural network with automatic architecture optimization, 2018.
- Moshe Kravchik and Asaf Shabtai. Efficient cyber attacks detection in industrial control systems using lightweight neural networks and pca, 2019.
- Yuqi Nie, Nam H. Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. A time series is worth 64 words: Long-term forecasting with transformers, 2023.
- Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting, 2022.
- Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis, 2023.
- Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. Are transformers effective for time series forecasting?, 2022.
- Ralf C. Staudemeyer and Eric Rothstein Morris. Understanding lstm – a tutorial into long short-term memory recurrent neural networks, 2019.
- Rahul Dey and Fathi M. Salem. Gate-variants of gated recurrent unit (gru) neural networks, 2017.
- Shaojie Bai, J. Zico Kolter, and Vladlen Koltun. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling, 2018.
- Jonathan Goh, Sridhar Adepu, Khurum Nazir Junejo, and Aditya P. Mathur. A dataset to support research in the design of secure water treatment systems. In Critical Information Infrastructures Security, 2016. URL <https://api.semanticscholar.org/CorpusID:3075307>.




Рис. 2: Корреляция выбранных 4 компонент со всеми компонентами системы SWaT. Фиолетовые значения показывают положительную корреляцию, коричневые - отрицательную. Значения датчиков 'FIT101', 'LIT101' сильно коррелируют друг с другом и с состоянием управляющего устройства 'MV101'.

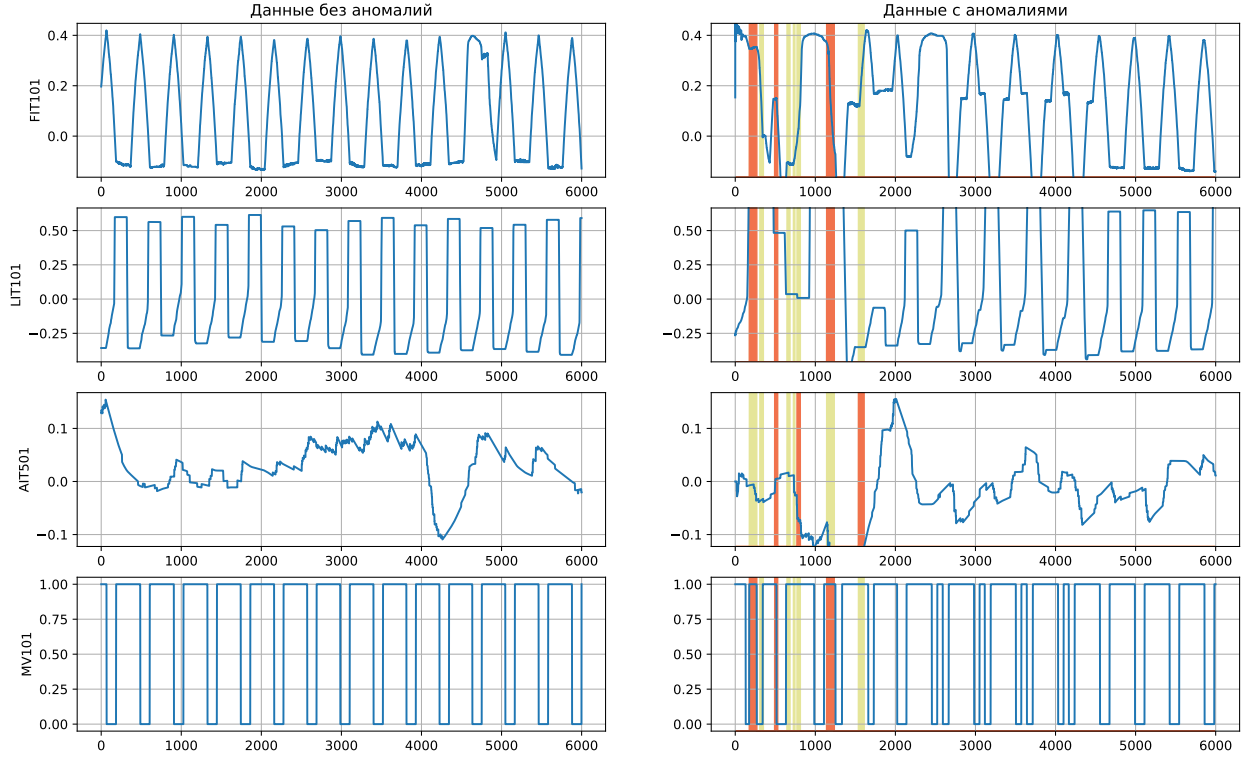


Рис. 3: Пример нормальных данных и данных с аномалиями после предобработки. Признаки 'FIT101', 'LIT101' и 'MV101' имеют сильно выраженную периодичность. Стандартное поведение значений может незначительно варьироваться. На данных с аномалиями изображена разметка аномальных зон: жёлтым цветом отмечены периоды атаки на систему в целом, красным - атаки, связанные с данным признаком. Можно заметить, что не все атаки на систему влияют на каждый признак. В аномальных зонах наблюдаются отличные от нормальных колебания значений, выход значений за стандартные границы и аперриодичное поведение.

Модель	Точность, %	Полнота, %	F1, %	Точность (с), %	Полнота (с), %	F1 (с), %	Доля обн-х аномалий	AD
TCN	65.0	77.0	70.4	77.9	92.3	84.5	0.66	199.6
Autoformer	58.1	76.8	66.2	69.9	92.4	79.6	0.6	199.1
TimesNet	58.4	78.7	67.0	69.7	94.0	80.1	0.66	198.0

Таблица 2: Результаты сравнения моделей для ряда 'FIT101'. AD - средняя задержка обнаружения. Точность (с), полнота (с) и F1-мера (с) - метрики, подсчитанные для обнаруженных зон, сдвинутых на 400 шагов назад. При сдвиге значения метрик выше, так как наблюдается задержка обнаружения аномалий.



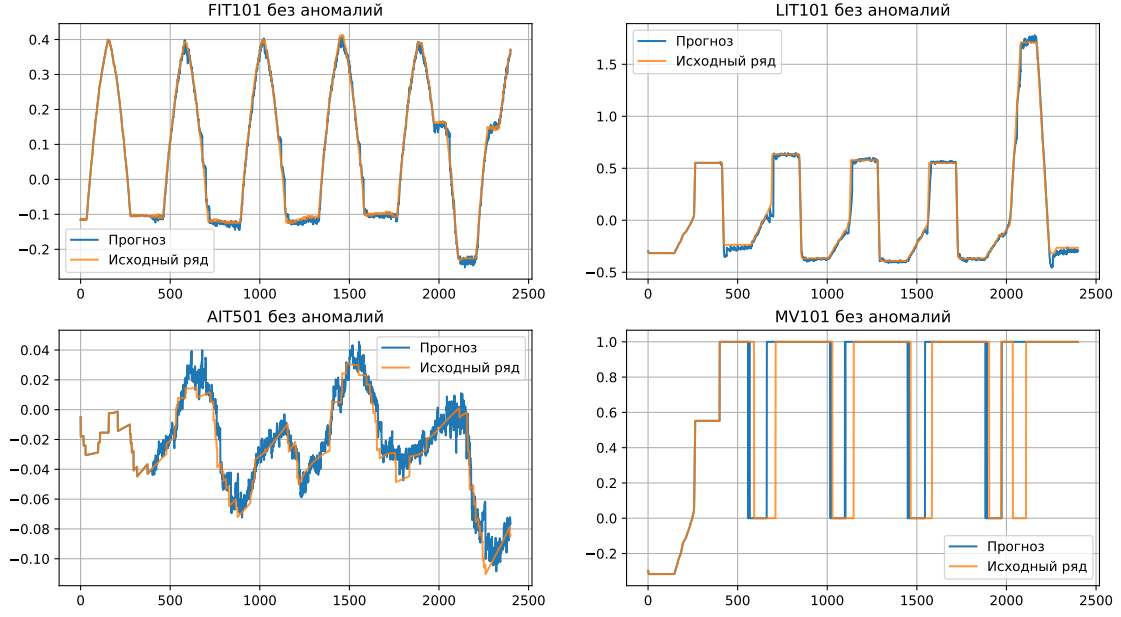


Рис. 4: Пример прогноза TCN для тестовых данных.

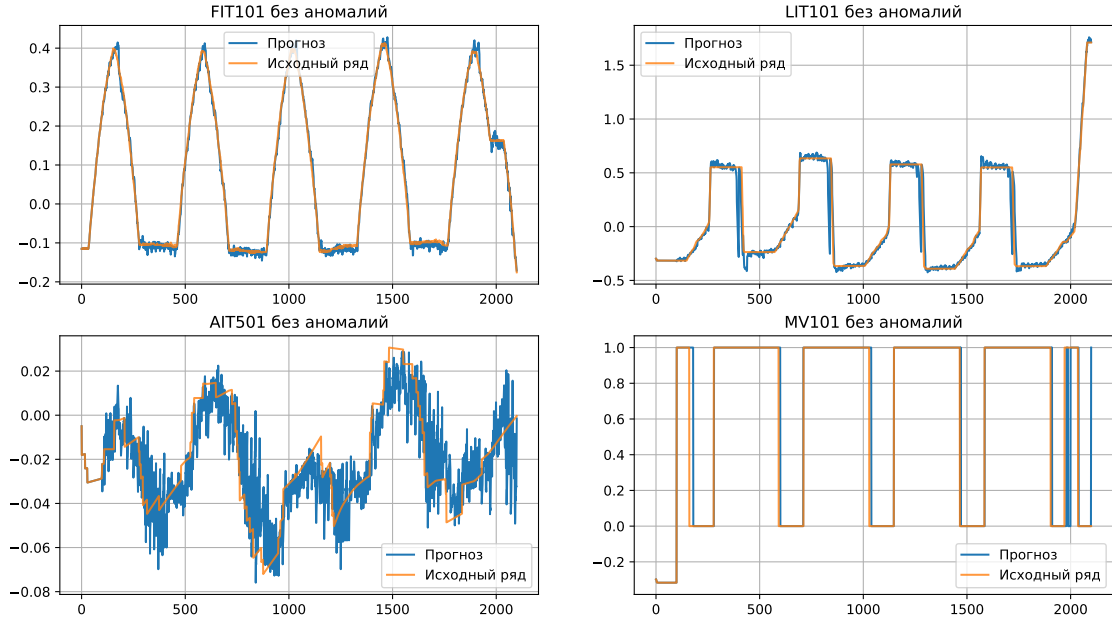


Рис. 5: Пример прогноза Autoformer для тестовых данных.

Таблица 3: Sample table title

Part		
Name	Description	Size ( $\mu\text{m}$ )
Dendrite	Input terminal	$\sim 100$
Axon	Output terminal	$\sim 10$
Soma	Cell body	up to $10^6$

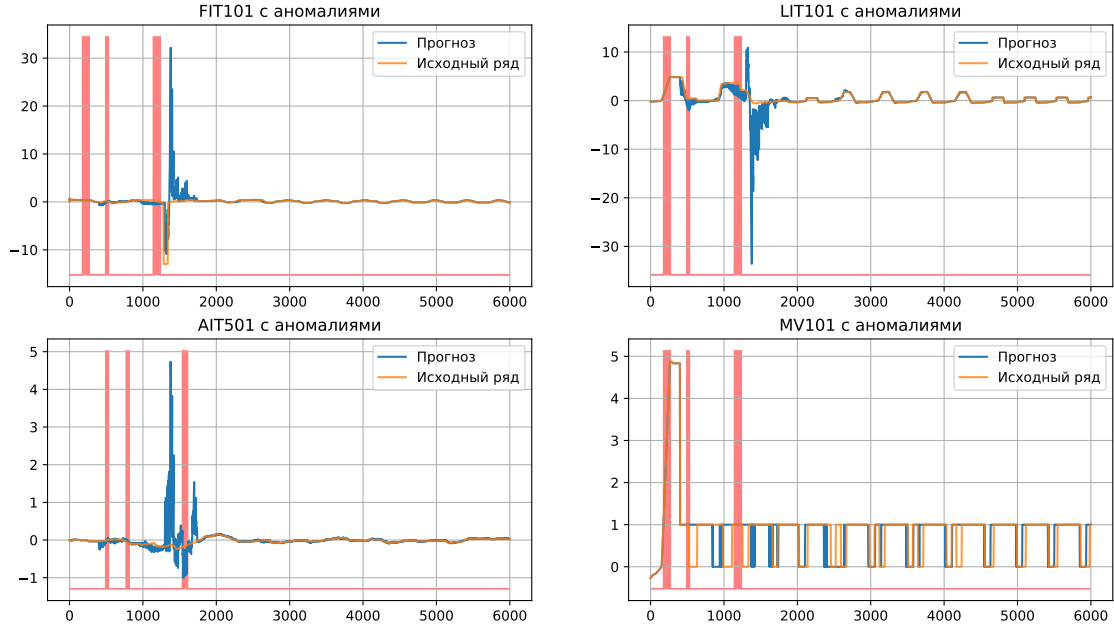


Рис. 6: Пример прогноза TCN для аномальных данных. Красным цветом отмечены аномальные зоны для данного ряда. Видно, что в аномальных зонах предсказанные значения существенно отличаются от типичных.

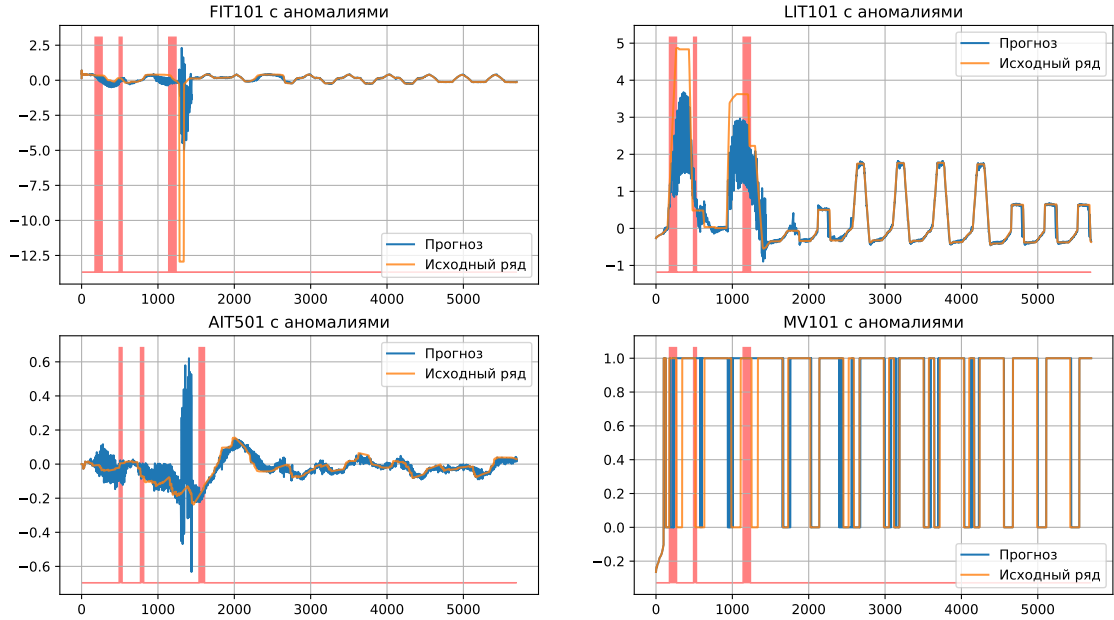


Рис. 7: Пример прогноза Autoformer для аномальных данных.




Рис. 8: Значения разности  $s$  для ряда 'FIT101'. Красным цветом отмечены аномальные зоны.




Рис. 9: Обнаружение аномалий для ряда 'FIT101'. Красным цветом отмечены аномальные зоны. Значение 1 показывает, что в данный момент времени зафиксирована аномалия.



Рис. 10: Sample figure caption.